

Avaliação de superpixels para segmentação de imagens

Felipe Augusto Lima Reis¹

¹PUC Minas - Pontifícia Universidade Católica de Minas Gerais

`falreis@sga.pucminas.br`

Abstract. *Superpixels are structures that group similar pixels into sets that reflect aspects of the image. This article evaluates the use of SLICO superpixels and partition hierarchy for segmentation. Using **neural networks** for segmentation, the results of superpixels images with different levels of granularity and untreated images were compared to the ground-truth. The article also evaluates the training time of neural networks for superpixels based images. For training and evaluation, the Berkeley Segmentation Data Set (BSDS500) [?] image was used.*

Resumo. *Superpixels são estruturas que agrupam pixels semelhantes em conjuntos que refletem aspectos da imagem. Este artigo avalia a utilização superpixels SLICO e hierarquia de partições para segmentação. Utilizando **redes neurais** para segmentação, os resultados de imagens utilizando superpixels com diferentes níveis de granularidade e imagens sem tratamento foram comparadas em relação ao ground-truth. O artigo também avalia o tempo de treinamento das redes neurais para imagens com superpixels em relação às imagens originais. Para treinamento e avaliação foram utilizadas imagem do Berkeley Segmentation Data Set (BSDS500) [?].*

1. Introdução

O presente trabalho apresenta a seguinte estrutura: a Seção ?? mostra o referencial teórico para construção do trabalho, a Seção ??, exibe os materiais e métodos utilizados nos testes; a Seção ?? mostra os resultados obtidos nos testes realizados e a discussões dos mesmos; a Seção ?? contém a conclusão do artigo, com as considerações finais.

2. Referencial Teórico

2.1. Superpixels

Superpixels são estruturas que agrupam pixels semelhantes em conjuntos. O agrupamento possibilita a redução de complexidade das tarefas de processamento [?], ao reduzir a quantidade de itens a serem processados. Os superpixels são utilizados na área de visão computacional para solução de vasto número de problemas, como detecção de contorno [?], segmentação [?] e localização de objetos [?].

Superpixels, segundo [?], devem capturar importante grupos ou regiões, refletindo aspectos da imagem. Devem também ser executados em tempo próximo ao linear em relação a quantidade de pixels. Existem diversas abordagens para a geração de superpixels [?]. Dentre elas, podemos classificá-las, segundo o método de agrupamento em:

- *Algoritmos baseados em grafos:* utilizam abordagem baseadas em grafos para correlação entre pixels e criação dos conjuntos;

- *Algoritmos baseados em gradiente ascendente*: utilizam métodos de gradiente ascendente iterativamente até que os critérios de convergência correspondam a forma de um superpixel;
- *Algoritmos de clusterização iterativo*: utilizam métodos de clusterização, como o k-means, para produção de superpixels.

Dentre os algoritmos de clusterização iterativos podemos citar o algoritmo SLIC (*Simple Linear Iterative Clustering*) [?]. Esse algoritmo é uma adaptação do algoritmo *k-means* para geração de superpixels, com diminuição de cálculos no processo de otimização, e combinação ponderada de cor e proximidade espacial, para permitir a definição do tamanho e capacidade dos superpixels [?].

O algoritmo utiliza um único parâmetro k , correspondente a quantidade aproximada de superpixels. A fim de produzir tamanhos semelhantes de superpixels, o intervalo analisado é $S = \sqrt{N/k}$.

To produce p roughly equally sized superpixels, the grid interval is $S = N/k$. The centers are moved to seed locations corresponding to the lowest gradient position in a 3×3 neighborhood. This is done to avoid centering a superpixel on an edge, and to reduce the chance of seeding a superpixel with a noisy pixel.

2.1.1. Algoritmo

SLIC superpixel segmentation

```

/* Initialization */
Initialize cluster centers  $C_k = [l_k, a_k, b_k, x_k, y_k]^T$  by
sampling pixels at regular grid steps  $S$ .
Move cluster centers to the lowest gradient position in a
 $3 \times 3$  neighborhood.
Set label  $l(i) = -1$  for each pixel  $i$ .
Set distance  $d(i) = \infty$  for each pixel  $i$ .

repeat
  /* Assignment */
  for each cluster center  $C_k$  do
    for each pixel  $i$  in a  $2S \times 2S$  region around  $C_k$  do
      Compute the distance  $D$  between  $C_k$  and  $i$ .
      if  $D < d(i)$  then
        set  $d(i) = D$ 
        set  $l(i) = k$ 
      end if
    end for
  end for
  /* Update */
  Compute new cluster centers.
  Compute residual error  $E$ .
until  $E \leq \text{threshold}$ 

```

Figura 1. Algoritmo SLIC - Adaptado de [?]

2.1.2. Complexidade

2.1.3. Medida de Distância

2.1.4. Outras Características

2.2. Segmentação

2.3. Redes Neurais

3. Materiais e Métodos

4. Testes, Resultados e Discussões

4.1. Subsections

Tabela 1. Variables to be considered on the evaluation of interaction techniques

	Value 1	Value 2
Case 1	1.0 ± 0.1	$1.75 \times 10^{-5} \pm 5 \times 10^{-7}$
Case 2	0.003(1)	100.0

5. Conclusão